.UBAECONÓMICAS

Tecnicatura en Gestión y Análisis de Datos

TALLER DE PROGRAMACIÓN PARA EL ANÁLISIS DE DATOS

U2 - Clase 6.1

Obtención de datos

Importación de archivos de datos

En esta clase veremos varias formas de obtener un conjunto de datos con Python en Colab y luego leerlo con Pandas.

Hay varias web que son repositorios de datos. Entre las más conocidas están
UCI: https://archive.ics.uci.edu/ml/datasets.php

Kaggle https://www.kaggle.com/datasets

Entre muchas otras más. La principal es Kaggle.

Los formatos más frecuentes son .csv o .zip

Es importante entender que es un DataFrame. Este es un conjunto de datos que posee filas (en general son los casos) y columnas (en general son las variables). Bajo esta estructura, es que tiene un formato de matriz. Lo que lo diferencia de esta es que un DataFrame admite datos de diferente tipo (podemos tener variables de texto y numéricas). En cambio las matrices solo admiten datos de un mismo tipo.
A su vez, al ser un formato matricial, Python recorrer el objeto con la misma lógica que se aprendió cuando se trabajó con matrices. Tendrá un índice implícito para las columnas y un índice fila.

A.Importación de archivos de datos desde la web

Ejemplo 1: leer un archivo .zip desde la web

Primero deberá obtener el url de descarga ingresando en la web correspondiente (en este ejemplo se utiliza el repositorio UCI)

Sentencia:

```
!wget https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip
```

Si el archivo fuese directamente un .csv entonces

```
!wget  [link]
```

El archivo se aloja en el menú de la izquierda en el cuaderno

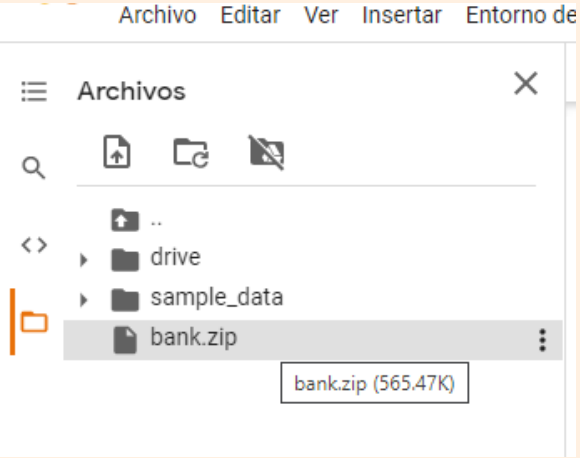

Para descomprimir el .zip

```
! unzip  /content/bank.zip
```

Se aloja en archivos, en el mismo lugar que el .zip

Luego se lee el archivo

```
import pandas as pd #se carga la librería pandas

data=pd.read_csv('/content/bank.csv', sep=';')
```

Se observan los primeros valores

```
data.head(5)
```

	age	job	marital	education
0	30	unemployed	married	primary
1	33	services	married	secondary
2	35	management	single	tertiary
3	30	management	married	tertiary
4	59	blue-collar	married	secondary

B.Importación manual

En el menú de la izquierda en el cuaderno, ir a archivos, y arriba seleccionar el botón de importar.

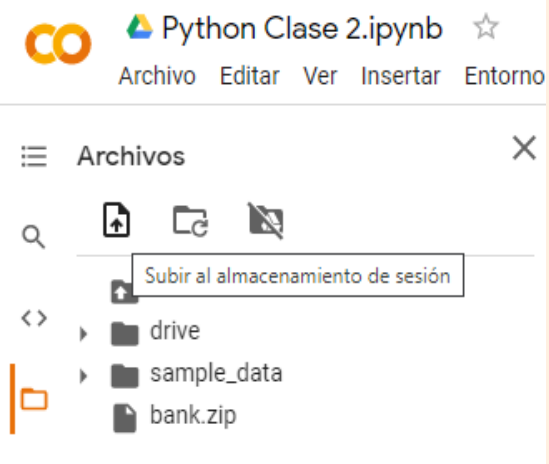

El archivo se alojará en el mismo lugar que los importados anteriormente. Luego se procede a la lectura del archivo con pandas, al igual que en el caso anterior.

Nota: tener en cuenta que un archivo subido a la sección del cuaderno actual donde se esté trabajando se pierde al cerrarlo. Entonces cada vez que se abra el cuaderno se deberá importar el archivo.

C. Conectarse al Google Drive propio

En el menú de la izquierda, seleccionar arriba, el logo de Drive.

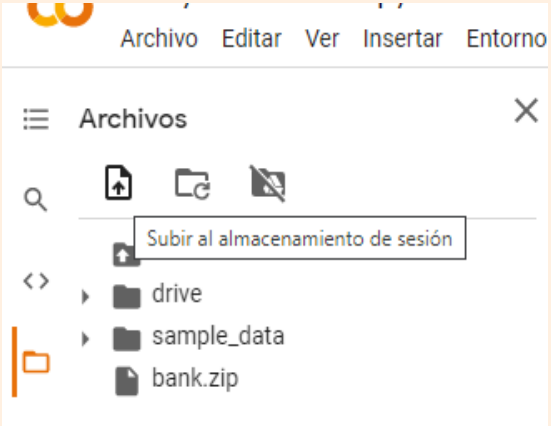

Si posee una cuenta de gmail, se conectará automáticamente logueándose con su cuenta. Luego en archivos, aparecerá una carpeta Drive y dentro de ella una subcarpeta MyDrive.

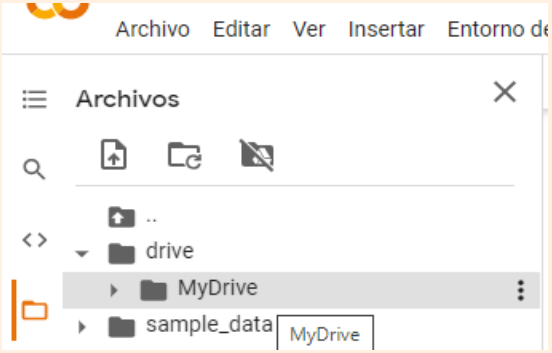

Si navega por esta última encontrará los archivos que tenga disponible en su Drive.
Luego, podrá leer los archivos utilizando pandas como en los casos anteriores.

C. Conectarse al Google Drive propio

Lo que se debe tener en cuenta es que puede leer el archivo porque se conecta a su Drive con sus credenciales.

Si comparte el cuaderno un tercero no tendrá acceso al archivo, es decir, no podrá leerlo.

Para que esto sea posible deberá compartir el archivo desde su Google Drive para obtener el link. De ese link deberá obtener el ID.

Obtener el link de un archivo compartido desde su Google Drive:

1. Acceder al Drive y buscar el archivo.
2. En los tres puntitos, seleccionar compartir:

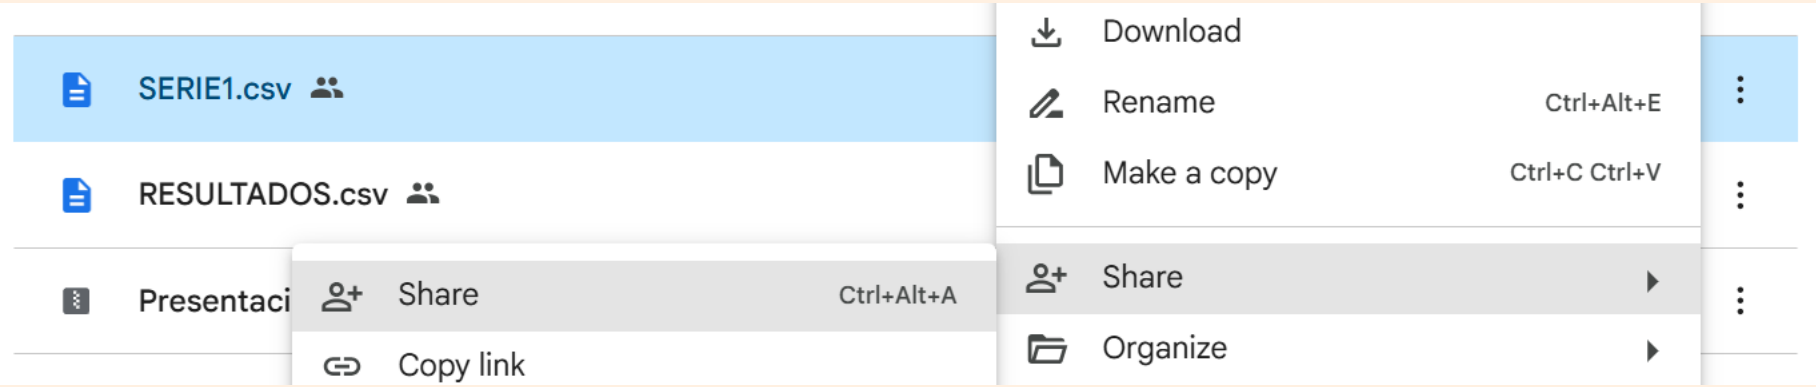

C. Conectarse al Google Drive propio

3. Seleccionar “Cualquier persona con el enlace”

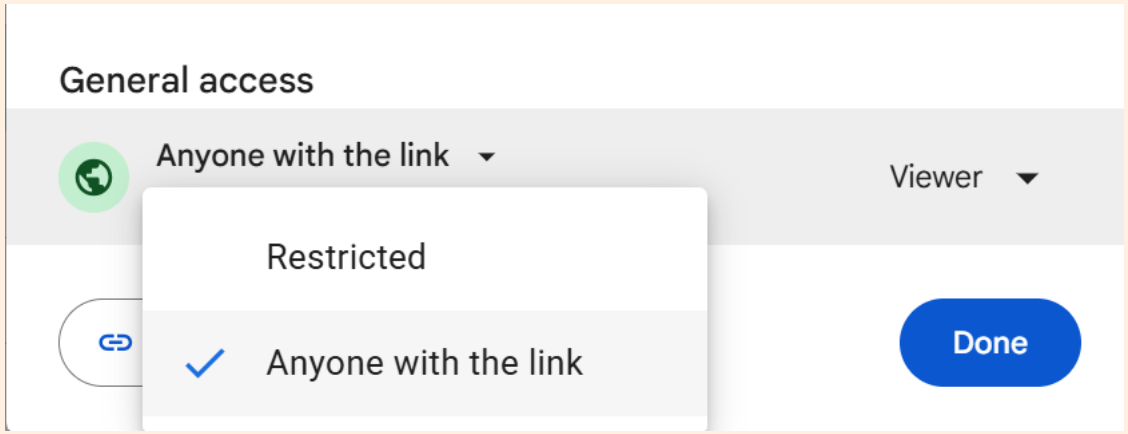

4. Luego, Copiar link:

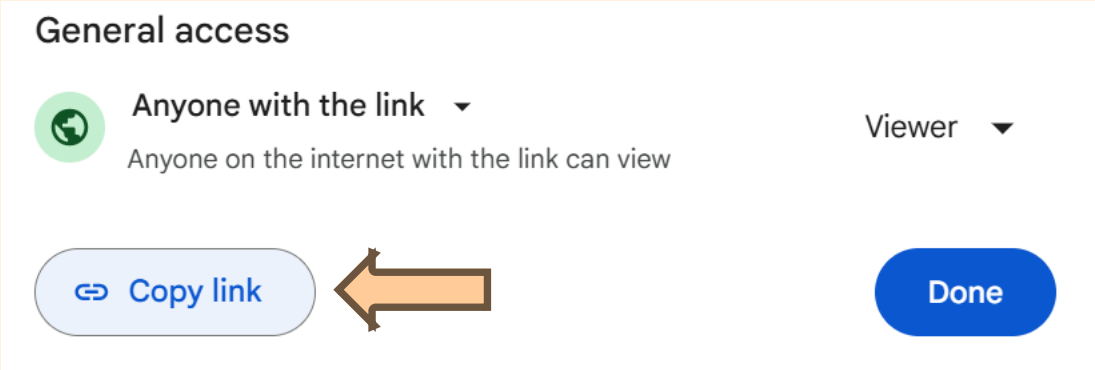

Al copiar link, recién entonces seleccionar Done
Por ejemplo, de este link obtenido, lo que necesita es el ID:
https://drive.google.com/file/d/1ktB9bvTQWlwqGTrVw6DRQFgbSuhzESaD/view?usp=sharing
Siendo lo resaltado en amarillo.

C. Conectarse al Google Drive propio

En su colab debe dejar todo el siguiente script:

```
!pip install -U -q PyDrive2
from pydrive2.auth import GoogleAuth
from pydrive2.drive import GoogleDrive
from google.colab import auth
from oauth2client.client import GoogleCredentials
```

Configuración en el Colab

```
auth.authenticate_user()
gauth = GoogleAuth()
gauth.credentials = GoogleCredentials.get_application_default()
drive = GoogleDrive(gauth)

#cuando corra este código le pide autorización para conectarse a
Drive Propio - seleccionar cuenta y luego ALLOW
```

Configuración de la descarga del archivo: aquí es donde incorporar el ID obtenido

```
fileDownloaded =
drive.CreateFile({'id':'1ktB9bvTQWlwqGTrVw6DRQFgbSuhzESaD'})
```

Descarga del archivo a través del ID seteado

```
fileDownloaded.GetContentFile('SERIE1.csv')
```

Luego que el archivo aparecerá donde siempre se observan los mismos en el Colab (menú de la izquierda), entonces proceder a leerlo con pandas.

D. Importar usando la API de Yahoo Finance

Yahoo Finance (https://finance.yahoo.com/) muestra al cotización de activos en la bolsa de EEUU. Para quienes trabajan con este tipo de datos, es una fuente predilecta.

En Python se creó una librería que hace una conexión directa a esta API. Una vez elegido algún activo podrá importar sus datos seleccionado períodos e incluso con distinta frecuencia (diaria, mensual, anual, etc)

```
#se carga librerías
import yfinance as yf

#se importan los datos de cotización para un caso a través de la API
GSP = yf.download('^GSPC', start='2021-09-29', end='2022-09-29')
GSP.head()
```

Ver en el colab de la clase distintos ejemplos.

E. Importar desde Kaggle

1. Ingresar a al repositorio de Kaggle: https://www.kaggle.com/

2. Ir a Datasets

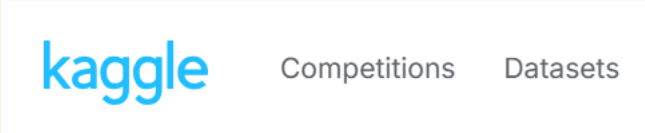

3. Buscar alguno de interés e ingresar en el mismo. Luego clickear en Download para obtener el código (copiarlo y llevarlo al Colab):

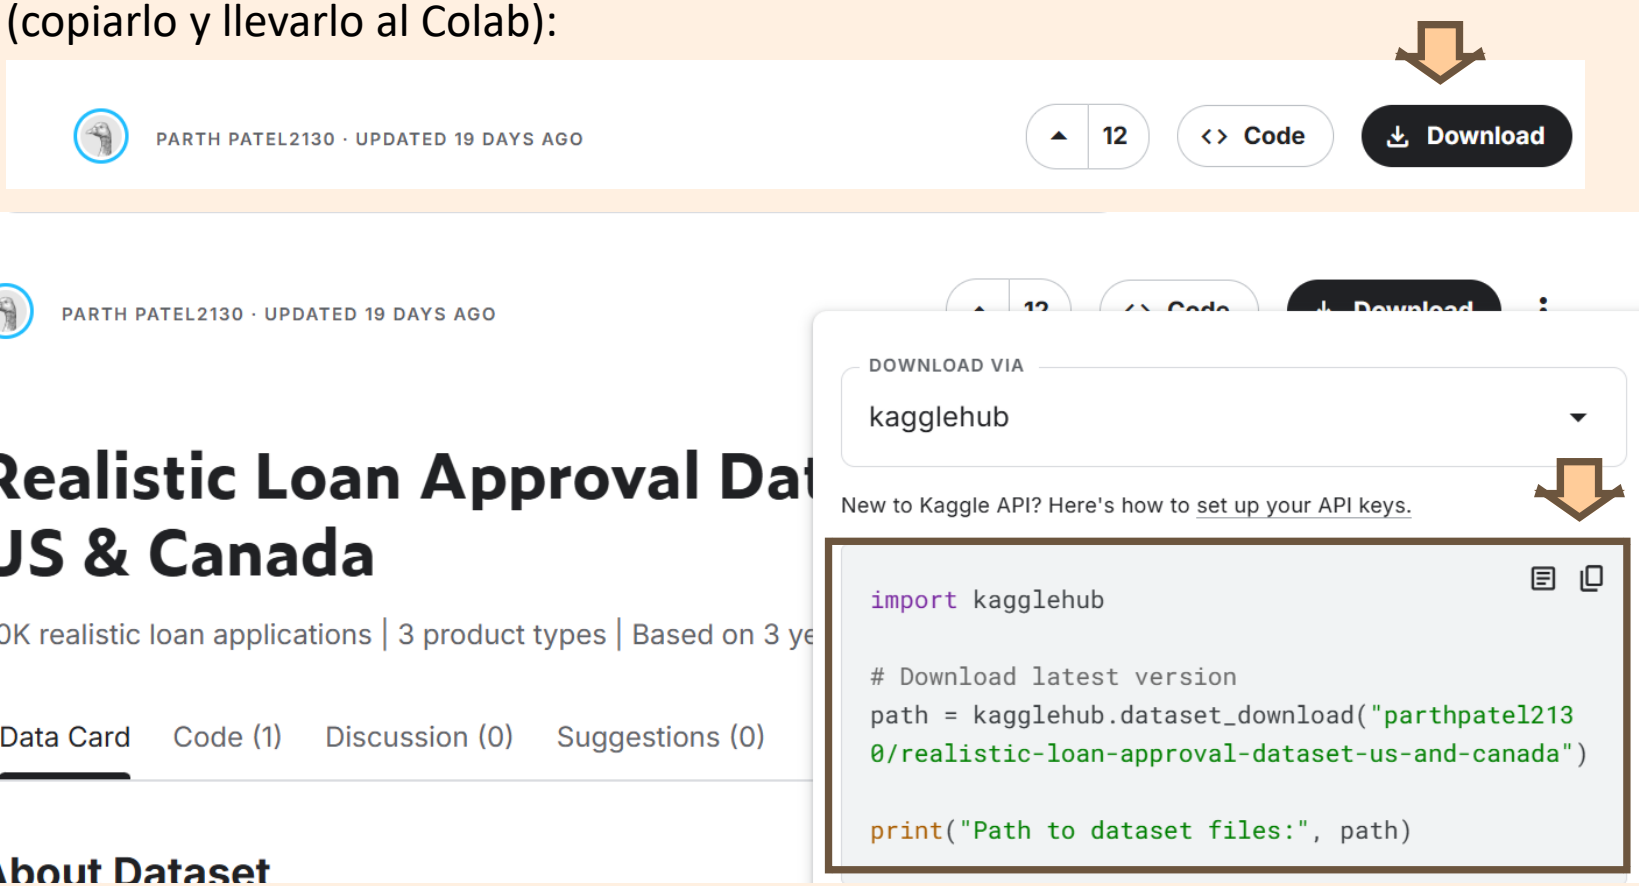

E. Importar desde Kaggle

4. Al ejecutar el código obtendrá el path donde se encuentra alojado el archivo, copiarlo:

```
import kagglehub

# Download latest version
path = kagglehub.dataset_download("parthpatel2130/realistic-loan-approval-dataset-us-and-canada")

print("Path to dataset files:", path)
```

```
Downloading from https://www.kaggle.com/api/v1/datasets/download/parthpatel2130/realistic-loan-approval-dat[illegible]s-and-canada?dataset_v
100%|[illegible]| 1.64M/1.64M [00:00<00:00, 113MB/s]Extracting files...
Path to dataset files: /root/.cache/kagglehub/datasets/parthpatel2130/realistic-loan-approval-dataset-us-and-canada/versions/1
```

5. Para leer el archivo csv de datos (en este caso contiene varios, elegir uno), agregarle al path el nombre del archivo y su extensión:

DATA=pd.read_csv("/root/.cache/kagglehub/datasets/parthpatel2130/realistic-loan-approval-dataset-us-and-canada/versions/1/Loan_approval_data_2025.csv")

DATA

Luego visualizará el DataFrame.

.UBAECONÓMICAS

Tecnicatura en Gestión y Análisis de Datos

¡MUCHAS GRACIAS POR SU ATENCIÓN!