.UBAECONÓMICAS

Tecnicatura en Gestión y Análisis de Datos

TALLER DE PROGRAMACIÓN PARA EL ANÁLISIS DE DATOS

U2 - Clase 6.2

Profiling Report

Profiling Report

Una vez que se obtiene un DataFrame en Colab con Python, la primer tarea que se debe realizar es poder conocer el comportamiento de los datos allí contenidos. Además, poder detectar problemas existentes como ser datos faltantes, variables (columnas) con distribuciones atípicas, datos atípicos.
Para ello, se realiza un Profiling Report (Informe de Perfil de Datos):

```
#se instala el módulo
!pip install ydata-profiling

#se importa la librería
from ydata_profiling import ProfileReport

#se crea el reporte
ProfileReport(DATA)
```

El reporte creado con esta librería solo es visible de manera online.

A los fines de elaborar un documento con el reporte, deberá redactar los resultados allí mostrados y podrá incorporar los gráficos como prints.

El reporte obtenido muestra diversa información. A continuación se destaca la principal.

Profiling Report – Información obtenida

En el **Overview** se muestra toda la información obtenida. El primer cuadra que aparece es información general:

Overview

Brought to you by YData

Overview | Alerts 19 | Reproduction

Dataset statistics

Number of variables	20
Number of observations	50000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%

Variable types

Text	1
Numeric	13
Categorical	6

De aquí puede saber cuantas variables (columnas) posee: 20, cuantas filas (casos o filas): 50.000, si existen valores faltantes (Mising cells): 0, en este caso ninguno, si existen filas duplicadas (Duplicate rows): 0, en este caos ninguna, y de que tipo son las variables: hay una string, 13 numércas y una categórica.

Profiling Report – Información obtenida

En el Overview, si accede a la pestaña **Alerts**, verá una cierta información que surge de las posteriores partes del reporte. Por ejemplo, tomando cierta parte:

`savings_assets` is highly overall correlated with `credit_history_years`	High correlation
`years_employed` is highly overall correlated with `age`	High correlation
`defaults_on_file` is highly imbalanced (69.9%)	Imbalance
`derogatory_marks` is highly imbalanced (72.6%)	Imbalance
`customer_id` has unique values	Unique
`years_employed` has 3459 (6.9%) zeros	Zeros
`delinquencies_last_2yrs` has 30797 (61.6%) zeros	Zeros

Se puede observar que:

- El nivel de correlación que existe entre variables
- Si alguna variable está desbalanceada (mayorías de casos para un valor)
- Si alguna variables tiene valores cero y cuantos son.

Profiling Report – Información obtenida

En la siguiente sección **Variables**, comienza a describir una por una las variables existente. En el caso de que una variable es String, será mínima la información obtenida, ya que no se puede calcular medidas. En cambio, las numéricas tendrá información completa. Por ejemplo, se mira la variable Age:

age

Real number (ℝ)

High correlation

Distinct	53	**Minimum**	18
Distinct (%)	0.1%	**Maximum**	70
Missing	0	**Zeros**	0
Missing (%)	0.0%	**Zeros (%)**	0.0%
Infinite	0	**Negative**	0
Infinite (%)	0.0%	**Negative (%)**	0.0%
Mean	34.95706	**Memory size**	390.8 KiB

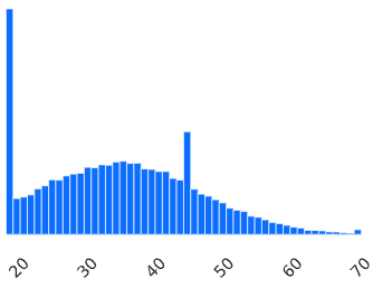

Se puede observar que:

- Tiene 53 valores distintos, ningún valor faltante (Missing), ningún valor demasiado grande (Infinite)
- La media de la variable, que es 34.95706, el valor mínimo=18, máximo=70
- Ningún valor cero (Zeros), Ningún valor negativo (Negative).
- Un histograma de la distribución de la variable.

Profiling Report – Información obtenida

En la parte inferior del gráfico tiene un botón **“more details”** que al seleccionarlo se le despliegan más estadísticas, que el permitirán analizar de manera más completa a la variable :

Statistics | Histogram | Common values | Extreme values

Quantile statistics		Descriptive statistics	
Minimum	18	**Standard deviation**	11.118603
5-th percentile	18	**Coefficient of variation (CV)**	0.31806459
Q1	26	**Kurtosis**	-0.43633607
median	35	**Mean**	34.95706
Q3	43	**Median Absolute Deviation (MAD)**	8
95-th percentile	54	**Skewness**	0.33586008
Maximum	70	**Sum**	1747853
Range	52	**Variance**	123.62333
Interquartile range (IQR)	17	**Monotonicity**	Not monotonic

También tiene una solapa:

- Histograma: donde visualizará más completo el histograma anterior
- Common values: donde observará los valores con mayor frecuencia de aparición
- Extreme Values: donde observará los 10 valores más bajos pero más frecuentes y los 10 valores más altos y más frecuentes

Todo esta información se repite para todas las variables, principalmente numéricas

Profiling Report – Información obtenida

En la siguiente sección **Interactions**, podrá graficas un Scatteplot que permite ver la relación entre dos variables. Este, en ves de ser con puntos, es con densidades (de concentración de valores)

El color azul más oscuro, muestra una mayor cantidad de valores relacionados,

Profiling Report – Información obtenida

En la siguiente sección **Correlations**, muestra gráficamente y por tabla de valores, el coeficiente de correlación lineal.

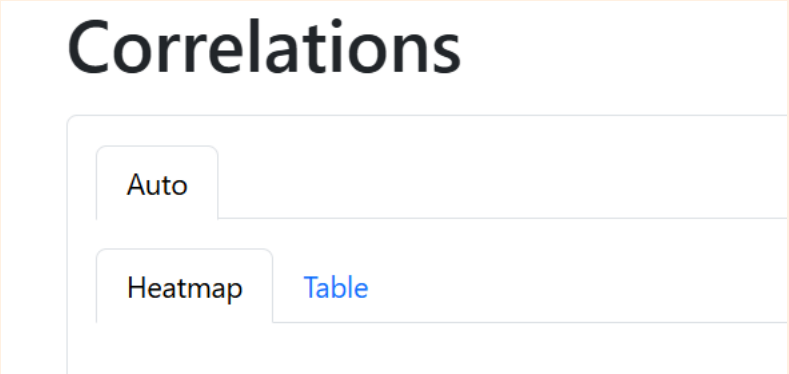

A partir de ello podremos saber el grado de asociación lineal entre las variables:

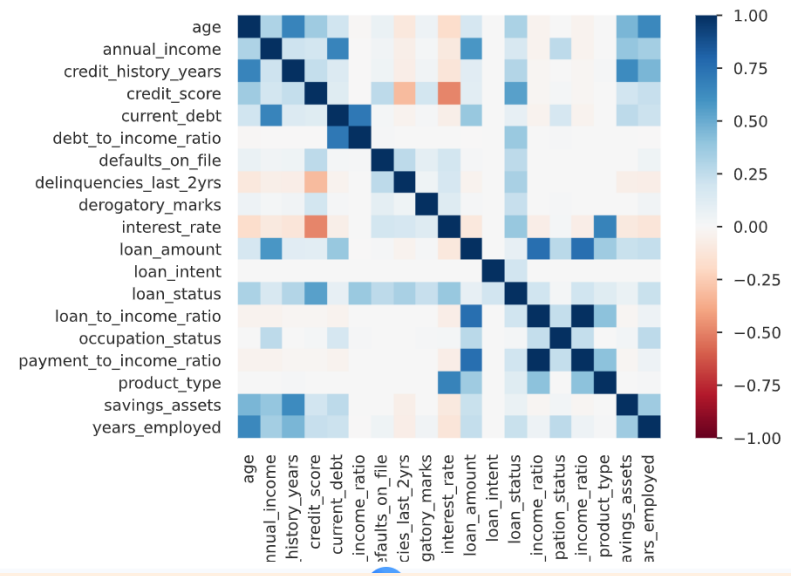

Profiling Report – Información obtenida

A partir de toda la información anterior, se podrá:

- Describir, a partir de las dimensiones iniciales, el conjunto de datos
- Analizar descriptivamente (medidas estadísticas) a las variables

- Detectar problemas como ser valores faltantes o valores extremos.

De esta manera, podrá realizar lo que se conoce en un informe como la presentación de datos con los cuales se trabajará, la detección de problemas y las descriptiva de comportamiento de las variables

.UBAECONÓMICAS

Tecnicatura en Gestión y Análisis de Datos

¡MUCHAS GRACIAS POR SU ATENCIÓN!