

.UBAECONÓMICAS



*Tecnicatura en
Gestión y Análisis
de Datos*

TALLER DE PROGRAMACIÓN PARA EL ANÁLISIS DE DATOS

U3 - Clase 17.2

Explicabilidad de
modelos

¿Qué es la explicabilidad de un modelo?

- Durante mucho tiempo sucedía que si bien los modelos de aprendizaje automático performaban mejor que un modelo tradicional, no era posible aproximar a una explicación de porque esto sucedía. Las consecuencias que se derivaban era que tales modelos no eran transparentes y por tanto no podían ser explicables.
- De este modo, existía un trade off entre exactitud y explicabilidad. En ocasiones se renunciaba a obtener mejores predicciones a partir del uso de nuevos modelos y en cambio se optaba por el uso de modelos tradicionales ya que sobre estos es posible saber porque obtiene buenos resultados (o no) o porque comete errores (o no).
- Frente a este escenario y con el avance del desarrollo científico, se han creado métodos que permiten alcanzar una respuesta al siguiente interrogante: ¿qué características influyen significativamente en el rendimiento del modelo de aprendizaje automático y qué características contribuyen a obtener las predicciones?
- De este modo, que un modelo sea explicable, significa poder comprender por la mente humana porqué tomó determinada decisión. En consecuencia, el modelo será interpretable convirtiéndolo en transparente lo que permitirá alcanzar un uso responsable.

Metodologías de explicabilidad de modelos

- Entre los métodos más utilizados en la actualidad para realizar la explicabilidad de un modelo se encuentra Shap (SHapley Additive exPlanations) Values . Se puede aplicar a cualquier modelo.
- El método Shap Values, proveniente de los “valores Shapley” introducidos en la teoría de juegos cooperativos ([Shapley 1953](#)), fue creado por Lundberg y Lee en 2017 (Ver [A Unified Approach to Interpreting Model Predictions](#)). Considera que cada valor de las predictoras es un jugador en un juego donde la predicción es el “pago”. A partir de ello, muestra como es posible distribuir equitativamente el “pago” entre las predictoras en cada etapa.
- De esta manera, para garantizar la interpretabilidad local, el método devuelve la contribución (el peso) de cada predictora en una predicción individual.

El método Shap Values


La idea general de cómo funciona el método puede interpretarse a través del siguiente ejemplo.

El objetivo es predecir el precio de una propiedad. Las características (predictoras) con las que se cuenta son la cantidad de habitaciones, la ubicación y la antigüedad. Supóngase que entrenó un modelo de aprendizaje automático y como resultado para una predicción obtuvo un valor de U\$107.000 mientras que el precio promedio predicho sobre todas las propiedades es de U\$100.000.

Ahora quiere saber cómo el modelo llegó a predecir tal precio a partir de las características dadas. Entonces la pregunta a realizarse en específico es: ¿Cuánto ha contribuido cada valor de las características a la predicción en comparación con la predicción promedio?

Para alcanzar una respuesta es necesario plantear todas las posibles combinaciones (submuestras) y con cada una de ellas obtener una predicción para luego determinar el valor Shap

El método Shap Values



El método Shap Values

Posibilidades de predicción utilizando de a una predictora cada vez

$U\$85 - U\$100 =$
-U\$15
Siendo el valor
Shaply

$U\$130 - U\$100 =$
U\$30
Siendo el valor
Shaply

$U\$105 - U\$100 =$
U\$5
Siendo el valor
Shaply


U\$85.000
Habitaciones

U\$130.000
Antigüedad

U\$105.000
Locación

U\$100.000
Sin predictoras

El método Shap Values



El método Shap Values

Si se sigue el camino marcado por las flechas naranjas, podemos determinar el peso de la predictora Habitaciones en cada instancia de predicción:

- 1 predictora (habitaciones) = $\frac{1}{3}$ (dado que es el peso de una sola predictora, entre tres)
- 2 predictoras (habitaciones y antigüedad ($\frac{1}{3}$), habitaciones y locación ($\frac{1}{3}$)) = $\frac{\frac{1}{3}}{2} = \frac{1}{6}$ (dado que se reparte el peso de la combinación de habitaciones en de dos predicciones)
- 2 predictoras (habitaciones y antigüedad y locación) = $\frac{1}{3}$ (dado que es el peso de una sola predictora conformada por habitaciones y el resto)

Entonces ahora es posible calcular la contribución marginal total de Habitaciones:


$$\frac{1}{3}(-15) + \frac{1}{6}(-12 - 15) + \frac{1}{3}(-3) = -\frac{21}{2} = -10,5$$

El valor Shap para la predictora Habitaciones es u\$-10,5 siendo la contribución marginal de esta predictora al valor de U\$107.000.

Si se repite el proceso para el resto de las predictoras se podrá saber la contribución marginal de cada una de las predictoras en la predicción del precio de la propiedad obtenido por el modelo original aplicado.


El método Shap Values

$$\frac{1}{3}(30) + \frac{1}{6}(33 + 5) + \frac{1}{3}(17) = 22$$



El método Shap Values

$$\frac{1}{3}(5) + \frac{1}{6}(5 - 20) + \frac{1}{3}(-11) = -\frac{9}{2} = -4.5$$



El método Shap Values

Por lo tanto, se tiene las contribuciones marginales que explican la predicción:

$$\frac{1}{3}(-15) + \frac{1}{6}(-27) + \frac{1}{3}(-3) = -\frac{21}{2} = -10,5 \text{ Habitaciones}$$

$$\frac{1}{3}(30) + \frac{1}{6}(38) + \frac{1}{3}(17) = 22 \text{ Antigüedad}$$

$$\frac{1}{3}(5) + \frac{1}{6}(-15) + \frac{1}{3}(-11) = -\frac{9}{2} = -4.5 \text{ Locación}$$


Luego la suma de las contribuciones marginales es:

$$-10,5 \text{ Habitaciones} + 22 \text{ Antigüedad} - 4.5 \text{ Locación} = 7$$

donde es posible comprobar que $7 = 107 - 100$

Obteniéndose la explicación de la diferencia entre lo predicho por el modelo y el verdadero valor

A modo de resúmen



Se parte de una predicción obtenida por algún modelo aplicado (lado izquierdo de la imagen). Allí se observa que el modelo predijo un valor de 0.4 a partir de valor de las predictoras utilizadas, tomando como base un valor de 0.1 (si fuese una regresión, el valor base es el intercepto).

Luego, con la metodología de Shap Value, es posible conocer cómo el modelo llega al valor predicho de 0.4, tomando como base 0.1, a través de conocer la contribución (el valor Shaply) de cada predictora. De este modo:

$$0.4 = 0.1 + 0.1 + 0.1 - 0.3 + 0.4$$

Además, permite saber en qué sentido es la contribución: rojo es en sentido positivo, azul es en sentido negativo.

.UBAECONÓMICAS



Tecnicatura en
Gestión y Análisis
de Datos

¡MUCHAS GRACIAS
POR SU ATENCIÓN!