

.UBAECONÓMICAS




*Tecnicatura en
Gestión y Análisis
de Datos*

TALLER DE PROGRAMACIÓN PARA EL ANÁLISIS DE DATOS

U3 - Clase 19


Análisis de sesgo,
varianza y equidad

Sesgo



El **sesgo** (Bias) de un modelo, refiere a errores sistemáticos (desviaciones respecto del valor real) que puede cometer un modelo de aprendizaje automático. Este ocurre cuando el algoritmo aprende y replica patrones o suposiciones que pueden no ser representativos del mundo real o pueden contener sesgos sociales existentes.

Tipos de sesgos en modelos



Casos típicos de sesgo en modelos de Machine Learning

Sesgo histórico

- Cuando el sesgo histórico se encuentra presente en los datos

Variables

- Cuando las predictoras se encuentran correlacionadas o asociadas con características sensibles (raza, religión, etc)

Muestras desbalanceadas

- Cuando los parámetros del modelo están sesgados hacia los de la mayoría

Algoritmo

- Cuando el modelo maximiza la exactitud a costas de la equidad


Retroalimentación

- Cuando el modelo sesgado conduce a obtener información más sesgada

- Para alcanzar un uso responsable de los modelos se deben implementar buenas prácticas que entre otras cosas implican:
 - Realizar una auditoría y control continuo de los modelos.
 - Asegurarse tener diversidad en los datos recolectados y procesados.
 - Realizar explicabilidad de los modelos
 - Capacitar y educar a las partes involucradas sobre sesgo y equidad

Sesgo vs Varianza en modelos

Cuando se utilizan modelos de Machine Learning se debe procurar obtener el menor Bias posible y la menor varianza posible en las predicciones realizadas para poder obtener la mejor performance posible (menor error posible).



Lo ideal, es el caso de Bajo Bias y Baja Varianza, aunque es muy difícil de conseguir operando con datos reales. En consecuencia, al utilizar modelos de aprendizaje automático se debe tener en cuenta que existirá un trade-off entre ambas.

Fuente: [Avati, \(2019\)](#) ; [Hoey, University of Waterloo](#); [Le Borgne, Y. \(2005\)](#); [Belkin et al.,\(2019\)](#); [Dar et al., \(2021\)](#); [Chen et al.,\(2023\)](#)

Sesgo vs Varianza en modelos de Machine Learning

$$\text{Bias}(\hat{Y}) = E(\hat{Y}) - Y$$

Bajo Bias: implica que se realizan menos cantidad de suposiciones al construir la función objetivo por lo que el modelo coincidirá estrechamente con el conjunto de datos de entrenamiento

Alto Bias: implica que se realizan más cantidad de suposiciones al construir la función objetivo por lo que el modelo no coincidirá estrechamente con el conjunto de datos de entrenamiento

$$\text{Variance} = E[(E(\hat{Y}) - \hat{Y})^2]$$

Baja Varianza: implica que el modelo es menos sensible a los cambios en los datos de entrenamiento y puede producir estimaciones consistentes con diferentes subconjuntos de datos que tengan la misma distribución. (se suele observar en el underfitting)

Alta Varianza: implica que el modelo es muy sensible a los cambios en los datos de entrenamiento y puede producir estimaciones muy diferentes con diferentes subconjuntos de datos que tengan la misma distribución. (se suele observar en el overfitting)

Sesgo vs Varianza en modelos de Machine Learning

Siendo:

$$Bias(\hat{Y}) = E(\hat{Y}) - Y \quad \quad \quad Variance = E[(E(\hat{Y}) - \hat{Y})^2] \quad \quad \quad Error = Y - \hat{Y}$$

donde Y es el valor real de la clase, $\hat{Y}$ el valor predicho, $E(\hat{Y})$ el valor esperado de la predicción.

Entonces, la pérdida esperada por error al cuadrado se descompone en sesgo y varianza:


$$E[(Y - \hat{Y})^2] = (Y - E(\hat{Y}))^2 + E[(E(\hat{Y}) - \hat{Y})^2]$$

$$\text{Pérdida esperada} = Bias^2 + Variance$$

A partir de ello, se observará que se produce un trade off entre bias y varianza. Esto es, los modelos que tratan de reducir el bias, implicará un aumento en la varianza; mientras que los que buscan reducir la varianza incrementarán el bias.

Nota: la varianza se definió de ese modo por conveniencia en la demostración

Equidad



La **equidad** (Fairness) de un modelo, refiere a la ausencia de discriminación o prejuicios en el proceso del accionar del modelo de aprendizaje automático (es decir, que el modelo sea justo). Esto, implica garantizar que el resultado del algoritmo no perjudique (para bien o mal) a ningún grupo en función de sus características particulares.

Problemas de equidad en modelos

TIPO DE PROBLEMAS

Distribución del perjuicio

Este ocurre cuando los modelos extienden o retienen oportunidades, recursos o información. Algunas de las aplicaciones clave están en los casos de contratación, admisión, y préstamos.

Calidad

Este ocurre cuando un modelo no funciona tan bien para una persona como para otra, incluso si no se extienden o retienen oportunidades, recursos o información. Ejemplos de casos son reconocimiento facial, la búsqueda de documentos o la recomendación de productos.

Estereotipos

Este ocurre cuando los modelos perpetúan los estereotipos. Por ejemplo, cuando los motores de búsqueda proponen completar el texto de la consulta parcialmente escrita.

Grupos

Este ocurre cuando los modelos omiten a un grupo en particular.

Fuente: [Barocas, S., Hardt, M., & Narayanan, A. \(2023\)](#) ; [Zanna y Sano, \(2024\)](#); [Fairlearn](#)

Métricas de evaluación de equidad

Accuracy equality

- Mide la exactitud de predicción del modelo por grupos sensibles

Statistical parity

- Mide la capacidad del modelo para hacer predicciones que sean independientes de la influencia de grupos sensibles

Equal opportunity

- Mide la disparidad en la tasa de verdaderos positivos entre grupos de características sensibles

Predictive equality

- Mide la disparidad en la tasa de falsos positivos entre grupos de características sensibles.

Equalized Odds

- Mide si un modelo proporciona igualdad de trato a todos los grupos.

Error rate

- Mide la proporción de errores entre todos los resultados para un grupo determinado.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas

La construcción de las métricas parte de descomponer la matriz de confusión por grupo

	Positivos	Negativos
Positivos	Verdaderos positivos (TP)	Falsos positivos (FP)
Negativos	Falsos negativos (FN)	Verdaderos negativos (TN)

Descomposición por grupo

Grupo mayoritario	Positivos	Negativos
Positivos	TP_p	FP_p
Negativos	FN_p	TN_p

Grupo minoritario	Positivos	Negativos
Positivos	TP_M	FP_M
Negativos	FN_M	TN_M

Métricas –Accuracy equality ratio

$$\text{Accuracy equality ratio} = \frac{\text{True positive} + \text{True Negative}}{\text{True positive} + \text{False positive} + \text{True Negative} + \text{False negative}}$$

Ejemplo: si se obtuvo la siguiente matriz de confusión

Riesgo malo (Bad), Riesgo bueno (Good), Mujer (M), H (Hombre)

	Bad	Good
Predicción Bad	25 (1 M, 24 H)	2 (1 M, 1 H)
Predicción Good	10 (7 M, 3 H)	23 (1 M, 22 H)

Se calcula la tasa por grupo (en este caso de género) y valor target

$$\text{Selection rate } M\text{Bad} = \frac{1 + 1}{1 + 1 + 1 + 7} = \frac{2}{10} = 20\%$$

$$\text{Selection rate } H\text{Bad} = \frac{24 + 22}{24 + 1 + 22 + 3} = \frac{46}{50} = 92\%$$

La tasa de exactitud por género es muy diferente, entonces no se cumple la igualdad de precisión. En consecuencia, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas -Statistical parity ratio

$$\text{Statistical parity ratio} = \frac{\text{True positive} + \text{False positive}}{\text{True positive} + \text{False positive} + \text{True Negative} + \text{False negative}}$$

Ejemplo: si se obtuvo la siguiente matriz de confusión

Riesgo malo (Bad), Riesgo bueno (Good), Mujer (M), H (Hombre)

	Bad	Good
Predicción Bad	25 (1 M, 24 H) TP	2 (1 M, 1 H) FP
Predicción Good	10 (7 M, 3 H) FN	23 (1 M, 22 H) TN

Se calcula la tasa por grupo (en este caso de género) y valor target

$$\text{Selection rate } M\text{Bad} = \frac{1 + 1}{1 + 1 + 1 + 7} = \frac{2}{10} = 20\%$$

$$\text{Selection rate } H\text{Bad} = \frac{24 + 1}{24 + 1 + 22 + 3} = \frac{25}{50} = 50\%$$

La tasa de paridad por género es muy diferente, entonces no se cumple la paridad estadística. En consecuencia, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas –Equal opportunity ratio

$$\text{Equal opportunity ratio} = \frac{\text{True positive}}{\text{True positive} + \text{False negative}}$$

Ejemplo: si se obtuvo la siguiente matriz de confusión

Riesgo malo (Bad), Riesgo bueno (Good), Mujer (M), H (Hombre)

	Bad	Good
Predicción Bad	25 (1 M, 24 H)	2 (1 M, 1 H)
Predicción Good	10 (7 M, 3 H)	23 (1 M, 22 H)

Se calcula la tasa por grupo (en este caso de género) y valor target

$$\text{True positive rate MBad} = \frac{1}{1 + 7} = \frac{1}{8} = 12,5\%$$

$$\text{True positive rate HBad} = \frac{24}{24 + 3} = \frac{24}{27} = 88.88\%$$

La tasa por género es muy diferente, entonces no se cumple la igualdad de oportunidades. En consecuencia, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas –Predictive equality ratio

$$\text{Predictive equality ratio} = \frac{\text{False positive}}{\text{True negative} + \text{False positive}}$$

Ejemplo: si se obtuvo la siguiente matriz de confusión

Riesgo malo (Bad), Riesgo bueno (Good), Mujer (M), H (Hombre)

	Bad	Good
Predicción Bad	25 (1 M, 24 H)	2 (1 M, 1 H)
Predicción Good	10 (7 M, 3 H)	23 (1 M, 22 H)

Se calcula la tasa por grupo (en este caso de género) y valor target

$$\text{False positive rate } M\text{Bad} = \frac{1}{1 + 1} = \frac{1}{2} = 50\%$$

$$\text{False positive rate } H\text{Bad} = \frac{1}{22 + 1} = \frac{1}{23} = 4.3\%$$

La tasa por género es muy diferente, entonces no se cumple la igualdad predictiva. En consecuencia, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas –Equalized Odds

Equalized Odds

$$P[h(X) = 1 \mid A = a, Y = 1] = P[h(X) = 1 \mid A = b, Y = 1] \quad P[h(X) = 1 \mid A = a, Y = 0] = P[h(X) = 1 \mid A = b, Y = 0]$$

Ejemplo: si se obtuvieron las siguientes matrices de casos

Ciudad 1	Empleado	Desempleado	Ciudad 2	Empleado	Desempleado
Predicción Bad	45	2	Predicción Bad	5	9
Predicción Good	45	8	Predicción Good	5	81

$$\% \text{ de Empleado y bad (TP rate)} = \frac{45}{90} = 50\%$$

$$\% \text{ de Empleado y bad (TP rate)} = \frac{5}{10} = 50\%$$

$$\% \text{ de Desmpleado y good (TN rate)} = \frac{8}{10} = 80\%$$

$$\% \text{ de Desmpleado y good (TN rate)} = \frac{81}{90} = 90\%$$

$$\% \text{ Total Ciudad 1 y bad} = \frac{47}{100} = 47\%$$

$$\% \text{ Total Ciudad 2 y bad} = \frac{14}{100} = 14\%$$

La tasa de *% de Empleado y bad* coinciden en ambas ciudades, pero la tasa de *% de Desmpleado y good* no coinciden. En consecuencia, no se cumple *Equalized Odds*, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

Métricas –Error rate

$$\text{Error rate} = \frac{\text{False positive} + \text{False negative}}{\text{True positive} + \text{False positive} + \text{False negative} + \text{True negative}}$$

Ejemplo: si se obtuvo la siguiente matriz de confusión

Riesgo malo (Bad), Riesgo bueno (Good), Mujer (M), H (Hombre)

	Bad	Good
Predicción Bad	25 (1 M, 24 H)	2 (1 M, 1 H)
Predicción Good	10 (7 M, 3 H)	23 (1 M, 22 H)

Se calcula el error rate por grupo (en este caso de género) y valor target

$$\text{Error rate } M = \frac{1 + 7}{1 + 1 + 7 + 1} = \frac{8}{10} = 80\%$$

$$\text{Error rate } H = \frac{1 + 3}{24 + 1 + 3 + 22} = \frac{4}{50} = 8\%$$

La tasa de error por grupo es muy diferente, entonces no se cumple la paridad. En consecuencia, se deberá mitigar el problema.

Fuente: [Mehrabi et. al. \(2019\)](#) ; [Pessach y Shmueli \(2020\)](#); [Brzezinski et. al. \(2024\)](#)

.UBAECONÓMICAS



Tecnicatura en
Gestión y Análisis
de Datos

¡MUCHAS GRACIAS
POR SU ATENCIÓN!